

生物医学图像处理课程大作业

Project 2: 皮肤病变图像深度学习分类实验报告

基于 ResNet18 与 MobileNetV2 的迁移学习

(请填写: 组长姓名、学号、组员及分工)

2026 年 5 月 27 日

摘要

本实验针对 Project 2 皮肤病变三分类任务 (mel、nv、vasc), 在预处理后的 **processed dataset** 上采用 ImageNet 预训练的 ResNet18 与 MobileNetV2 进行迁移学习。训练集进一步按病灶原图 ID 分组划分验证集, 在独立测试集 (120 张) 上评估, 并分别统计原图与增强图子集的表现。实验表明: MobileNetV2 在测试集整体准确率与 Macro-F1 上优于 ResNet18 (83.33% vs. 79.17%, Macro-F1 0.840 vs. 0.797); 在增强图子集 ($n=91$) 上 MobileNetV2 准确率为 79.1%, 高于 ResNet18 (75.8%) 及传统随机森林 (71.4%)。与 **final_project** 手工特征分类器相比, 深度学习整体准确率提升约 10 个百分点 (83.33% vs. 73.33%)。

目录

1	实验背景与任务目标	3
1.1	课程任务说明	3
1.2	本实验目标	3
2	数据集与预处理	3
2.1	原始数据	3
2.2	预处理流程	3
2.3	划分方案	4
3	方法	4
3.1	迁移学习框架	4
3.2	数据增强 (仅训练阶段)	5
3.3	评估指标	5
4	实验设置	5

目录	2
5 实验结果	5
5.1 总体性能对比	5
5.2 测试集：原图与增强图性能差距	6
5.3 测试集分类报告（MobileNetV2，最佳模型）	7
5.4 混淆矩阵	7
5.5 训练曲线与错例可视化	8
5.6 训练策略改进	11
6 结果分析与讨论	12
6.1 模型对比	12
6.2 原图与增强图鲁棒性	12
6.3 类别不平衡	12
6.4 局限性	12
7 传统方法 vs 深度学习对比分析	13
7.1 传统方法流水线概述	13
7.2 总体性能对比	13
7.3 原图与增强图子集对比	14
7.4 各类别 per-class 表现	14
7.5 数据划分与评测可信度	15
7.6 方法特性与适用场景	16
8 结论	16
参考文献	17
A 复现实验命令	17
B 小组成员分工（请填写）	17

1 实验背景与任务目标

1.1 课程任务说明

Project 2 要求从皮肤病变图像中提取特征并完成多类分类，并通过对**增强图像**的识别能力体现算法鲁棒性。数据集共 600 张图像：200 张原图与 400 张由数据增强(*_aug1、*_aug2)得到的增强图，类别为：

- **mel**: 黑色素瘤 (Melanoma)
- **nv**: 痣 (Nevus)
- **vasc**: 血管病变 (Vascular lesion)

1.2 本实验目标

1. 使用 **ResNet18** 与 **MobileNetV2** 进行迁移学习分类；
2. 完成训练集、验证集、测试集的划分与模型训练；
3. 对比深度模型在**原图**与**增强图**上的分类表现，分析鲁棒性。

说明：课程第 15 周定量评测要求使用传统图像处理或简单机器学习方法；本报告所述深度学习结果为课堂展示与课程报告所用，与传统方法形成互补对比。

2 数据集与预处理

2.1 原始数据

原始数据位于 Data_Proj2/, 包含 image/、mask/ 及 label.csv (600 条记录)。

2.2 预处理流程

小组成员已完成统一预处理 (见 processed dataset/demo.ipynb), 主要步骤为：

1. 尺寸归一化至 256×256 ;
2. 基于形态学 Black-hat 的轻度去毛发 (Telea 修复);
3. LAB 色彩空间下对 L 通道做亮度归一化 (范围约 30-220)。

2.3 划分方案

预处理输出保存在 `processed dataset/`:

表 1: 官方预处理划分 (stratify 分层抽样, random_state=42)

子集	样本数	原图	增强图	类别分布 (nv/mel/vasc)
训练 (官方)	480	171	309	240 / 168 / 72
测试 (官方)	120	29	91	60 / 42 / 18
合计	600	200	400	300 / 210 / 90

深度学习阶段在官方训练集 (480 张) 上, 按**病灶原图编号** (如 42_aug2 $\rightarrow$ 42) 进行 **GroupShuffleSplit**, 再划分出约 20% 作为验证集, 以避免同一病灶的原图与增强图同时出现在训练与验证中:

表 2: 深度学习训练/验证划分 (VAL_RATIO=0.2, SEED=42)

子集	样本数	原图	增强图
训练 (模型拟合)	387	138	249
验证 (调参与早停)	93	33	60
测试 (最终评估)	120	29	91

3 方法

3.1 迁移学习框架

- **骨干网络**: torchvision 提供的 ResNet18、MobileNetV2, 权重为 ImageNet-1K 预训练;
- **分类头**: 将最后一层全连接替换为 3 类输出;
- **输入**: 256×256 RGB, ImageNet 均值/方差归一化;
- **损失函数**: 交叉熵 (CrossEntropyLoss);
- **优化器**: Adam ($lr = 10^{-4}$, weight decay 10^{-4});
- **学习率调度**: 验证准确率 plateau 时乘以 0.5 (patience=3);
- **早停**: 验证集准确率连续 8 个 epoch 无提升则停止。

3.2 数据增强（仅训练阶段）

训练时对预处理图像施加在线增强：随机水平翻转、 $\pm 15^\circ$ 旋转、轻度 ColorJitter；验证与测试仅做 resize 与归一化。

3.3 评估指标

- **Accuracy**（准确率）
- **Macro-F1**（宏平均 F1，兼顾类别不平衡）
- 混淆矩阵及每类 Precision / Recall / F1

按 image_id 是否包含 _aug 将样本划分为原图子集与增强图子集，分别统计上述指标。

4 实验设置

表 3: 超参数与运行环境（deep_learning/config.py）

项目	设置
批大小（batch size）	16
最大训练轮数	30
验证集比例	0.2（按病灶分组）
随机种子	42
实现框架	PyTorch + torchvision
代码入口	py -m deep_learning.main
权重保存	outputs/checkpoints/{backbone}_best.pt
结果输出	outputs/results/

5 实验结果

5.1 总体性能对比

表 4 汇总两模型在验证集与测试集上的准确率与 Macro-F1（数据来源于 outputs/results/model

表 4: ResNet18 与 MobileNetV2 分类性能对比

模型	数据集	子集	n	Accuracy	Macro-F1
ResNet18	val	全部	93	0.774	0.780
	val	原图	33	0.788	0.792
	val	增强图	60	0.767	0.774
	test	全部	120	0.792	0.797
	test	原图	29	0.897	0.899
	test	增强图	91	0.758	0.760
MobileNetV2	val	全部	93	0.763	0.776
	val	原图	33	0.667	0.665
	val	增强图	60	0.817	0.833
	test	全部	120	0.833	0.840
	test	原图	29	0.966	0.971
	test	增强图	91	0.791	0.793

5.2 测试集：原图与增强图性能差距

表 5: 测试集上原图 vs. 增强图的准确率差距 ($\Delta = \text{原图 Acc} - \text{增强图 Acc}$)

模型	原图 Acc	增强图 Acc	Δ
ResNet18	89.7%	75.8%	+13.9 pp
MobileNetV2	96.6%	79.1%	+17.5 pp

ResNet18 在测试原图上表现突出 (89.7%)，增强图回落至 75.8% (差距约 14 pp)。MobileNetV2 测试原图准确率达 96.6% ($n=29$ ，样本量小，可能受划分泄漏影响偏乐观)，增强图为 79.1%，为两深度模型中**增强子集最高**；整体测试 Macro-F1 为 0.840，优于 ResNet18 的 0.797。

5.3 测试集分类报告（MobileNetV2，最佳模型）

表 6: MobileNetV2 测试集整体 per-class 指标

类别	Precision	Recall	F1-score	Support
mel	0.85	0.79	0.81	42
nv	0.83	0.83	0.83	60
vasc	0.81	0.94	0.87	18
accuracy			0.83	120
macro avg	0.83	0.85	0.84	120

表 7: ResNet18 测试集整体 per-class 指标

类别	Precision	Recall	F1-score	Support
mel	0.81	0.69	0.74	42
nv	0.78	0.83	0.81	60
vasc	0.80	0.89	0.84	18
accuracy			0.79	120
macro avg	0.80	0.80	0.80	120

ResNet18 对 **mel** 的召回率偏低（0.69），是拉低增强子集表现的主要因素之一；MobileNetV2 在三类上更为均衡，**vasc** 召回率达 0.94。

5.4 混淆矩阵

混淆矩阵行表示真实类别，列表示预测类别，顺序均为 mel / nv / vasc。

表 8: MobileNetV2 测试集混淆矩阵（ $n = 120$ ）

真实 \ 预测	mel	nv	vasc
mel	33	9	0
nv	6	50	4
vasc	0	1	17

表 9: ResNet18 测试集混淆矩阵 ($n = 120$)

真实 \ 预测	mel	nv	vasc
mel	29	12	1
nv	7	50	3
vasc	0	2	16

表 10: MobileNetV2 测试集——增强图子集混淆矩阵 ($n = 91$)

真实 \ 预测	mel	nv	vasc
mel	22	8	0
nv	6	39	4
vasc	0	1	11

表 11: ResNet18 测试集——增强图子集混淆矩阵 ($n = 91$)

真实 \ 预测	mel	nv	vasc
mel	19	10	1
nv	7	39	3
vasc	0	1	11

主要误分类模式：mel 与 nv 之间的相互混淆（两模型均有 7–15 例量级）；ResNet18 将部分 mel 误判为 vasc（1 例），增强子集上 mel→nv 误判更为突出。

5.5 训练曲线与错例可视化

图 1–2 为两模型训练/验证损失及准确率、Macro-F1 曲线；图 3–4 为测试集部分错例（真标签 → 预测标签）。由 `py -m deep_learning.main --plot` 根据 `*_history.json` 与预测 CSV 生成，保存在 `deep_learning/outputs/figures/`。




图 1: ResNet18 训练曲线（损失与准确率 / Macro-F1）




图 2: MobileNetV2 训练曲线

MobileNetV2 错例中 mel 误判为 nv 仍占多数；ResNet18 在增强样本上错例更多。




图 3: MobileNetV2 测试集错例示意 (优先展示 mel 相关误判)

resnet18 — test 错例 (共 25 张)




图 4: ResNet18 测试集错例示意

5.6 训练策略改进

后续训练默认启用：**类别加权交叉熵**（缓解 nv/mel/vasc 不平衡）、以验证集 **Macro-F1** 选取最佳 checkpoint（而非单纯准确率）。复现命令见附录；推理输出 `output_{backbone}.csv` 可由 `--predict` 生成。

6 结果分析与讨论

6.1 模型对比

在独立测试集上，**MobileNetV2** 整体优于 **ResNet18**（准确率 83.33% vs. 79.17%，Macro-F1 0.840 vs. 0.797）。尽管 ResNet18 参数量更大，在本任务有限样本（600 张）及已预处理数据上，轻量级 MobileNetV2 配合迁移学习取得了更好泛化；在增强测试子集上亦以 79.1% 高于 ResNet18 的 75.8%。

6.2 原图与增强图鲁棒性

Project 2 强调对增强图像的识别鲁棒性。实验表明：

- **ResNet18**: 测试集原图准确率（89.7%）高于增强图（75.8%），差距约 14 pp，对离线增强（旋转、翻转）泛化不足；
- **MobileNetV2**: 增强图准确率 79.1%，为深度模型中最高；原图准确率达 96.6%（ $n=29$ ），与原图-增强图差距约 17.5 pp，部分源于原图子集样本少及划分泄漏带来的乐观估计，应以增强子集指标衡量鲁棒性。

验证集上 MobileNetV2 呈现“增强优于原图”的趋势，与测试集原图子集高准确率并存，与验证/测试原图样本量均较小（ $n=33 / 29$ ）有关，最终以增强子集与整体测试集为准。

6.3 类别不平衡

数据集中 nv 样本最多，vasc 最少。MobileNetV2 对 vasc 召回率达 0.94、F1 为 0.87；ResNet18 对 mel 召回为 0.69，临床意义下 melanoma 漏检风险相对更高，可结合代价敏感学习或重采样进一步优化。

6.4 局限性

1. 官方 train/test 按单张 image_id 随机划分，不同增强版本可能分属训练与测试，存在病灶级信息泄漏的可能；本实验仅在 train→val 划分时按病灶分组缓解；
2. 测试集增强图占比高（91/120），评测结果更侧重增强分布；
3. 与传统方法的对比见第 7 节；深度学习未复现成员 4 的全部图像扰动实验，鲁棒性结论主要基于原图/增强图子集划分。

7 传统方法 vs 深度学习对比分析

本节基于 `final_project/` 中小组已完成的传统流水线, 与 `deep_learning/` 实验结果进行同数据集、同官方划分 (训练 480 / 测试 120, `random_state=42`) 的并列对比。传统方法数据来自 `results/model_comparison.csv`、`results_member4/augmentation_consistency.csv` 与 `results_member4/group_split_summary.csv`; 深度学习方法数据来自 `deep_learning/outputs/r`

7.1 传统方法流水线概述

传统方案由小组成员分模块完成 (详见 `final_project/README.md`):

1. **预处理** (成员 1): 与深度学习共用同一套 `processed dataset` (256×256 、去毛发、亮度归一化);
2. **特征工程** (成员 2): 从 RGB 图像提取 127 维手工特征——颜色矩 (9 维)、RGB 直方图 (96 维)、GLCM 纹理 (12 维)、LBP 纹理 (10 维), 经 `StandardScaler` 归一化 (可选 PCA 降至 36 维, 最终评测使用 127 维);
3. **分类器** (成员 3): 对 SVM (RBF)、随机森林 (RF)、KNN 进行 `GridSearchCV` (5 折分层交叉验证), 在测试集上报告 Accuracy 与 Macro-F1;
4. **鲁棒性扩展** (成员 4): 分析增强图一致性、图像扰动及严格按病灶编号分组划分下的性能波动。

7.2 总体性能对比

表 12 汇总各方法在官方测试集 ($n = 120$) 上的整体指标。传统方法中 **随机森林 (RF)** 准确率最高 (73.33%), 与 SVM (72.50%) Macro-F1 相当 (均为 0.736); KNN 明显落后 (66.67%)。深度学习中 **MobileNetV2** 全面领先: 准确率 83.33%、Macro-F1 0.840, 较最佳传统方法 RF 分别提升约 **10.0 pp** 与 **0.104**; ResNet18 亦优于全部传统模型 (79.17% / 0.797)。

表 12: 传统机器学习 vs. 深度学习: 测试集整体性能 ($n = 120$)

范式	模型	Accuracy	Macro-F1	备注
传统 (手工特征)	Random Forest	0.733	0.736	最佳传统准确率
	SVM (RBF)	0.725	0.736	少数类 <code>vasc</code> 召回略优
	KNN	0.667	0.672	$k=1$, 曼哈顿距离
深度学习 (迁移学习)	MobileNetV2	0.833	0.840	本实验最佳
	ResNet18	0.792	0.797	参数量更大

7.3 原图与增强图子集对比

Project 2 强调对增强图像的识别能力。测试集中含原图 29 张、增强图 91 张(*_aug1、*_aug2)。表 13 对比各方法在两类子集上的准确率及原图-增强图差距 Δ 。

表 13: 原图 vs. 增强图测试准确率及差距 Δ (pp = 百分点)

模型	原图 Acc ($n=29$)	增强图 Acc ($n=91$)	Δ	说明
SVM (传统)	89.7%	67.0%	+22.7	增强图表现最差
Random Forest (传统)	79.3%	71.4%	+7.9	传统中最均衡
KNN (传统)	75.9%	63.7%	+12.2	对增强图敏感
ResNet18	89.7%	75.8%	+13.9	原图高、增强回落明显
MobileNetV2	96.6%	79.1%	+17.5	增强子集最佳

注：传统方法增强子集准确率为 *augmentation_consistency.csv* 中 *_aug1* (45 张) 与 *_aug2* (46 张) 子集准确率的样本数加权平均。

主要发现如下：

- **绝对性能：** MobileNetV2 在增强图子集 (79.1%) 上较最佳传统 RF (71.4%) 高出约 8 pp，亦高于 ResNet18 (75.8%)；
- **泛化均衡性：** 传统 RF 的原图-增强差距 (7.9 pp) 最小；深度模型原图准确率普遍偏高，MobileNetV2 原图达 96.6% ($n=29$)，提示需结合严格病灶分组评估，不宜单独依据原图子集判断鲁棒性；
- **共同难点：** mel 与 nv 互混仍是主要误分类来源（见错例图）。

7.4 各类别 per-class 表现

表 14 对比最佳传统模型 RF 与最佳深度模型 MobileNetV2 的测试集各类 F1。两者共同难点为 **mel** $\leftrightarrow$ **nv** 混淆；深度学习在三类上均优于传统方法，尤其对 mel (0.81 vs. 0.71) 与 vasc (0.87 vs. 0.76) 提升明显。深度 MobileNetV2 将 mel 召回提升至 0.79，有利于降低黑色素瘤漏检风险。

表 14: 测试集各类 F1-score: Random Forest (传统) vs. MobileNetV2 (深度)

类别	RF (传统)	MobileNetV2	Δ F1
mel	0.707	0.810	+0.103
nv	0.744	0.830	+0.086
vasc	0.757	0.870	+0.113
macro avg	0.736	0.840	+0.104

7.5 数据划分与评测可信度

成员 4 指出：当前官方划分按单张 `image_id` 随机分层，去除 `_aug1/_aug2` 后缀后，训练集与测试集存在 **98 个共同病灶编号**（共 200 个原图编号），即同一病灶的原图/增强图可能分属训练与测试，造成信息泄漏，使测试指标偏乐观。

在**严格按病灶编号分组**（10 次随机，训练/测试病灶零重叠）下，传统方法 Macro-F1 均值显著下降（表 15）。深度学习仅在 `train→val` 阶段采用 `GroupShuffleSplit` 缓解泄漏，测试集仍使用官方划分，故与传统“官方划分”结果可直接对比，但双方均需在答辩中说明严格分组下的预期性能折损。

表 15: 严格病灶分组（10 次均值 $\pm$ 标准差）下的 Macro-F1

模型	Macro-F1 (mean $\pm$ std)	相对官方划分 RF (0.736)
Random Forest (传统)	0.578 $\pm$ 0.035	-0.158
SVM (传统)	0.515 $\pm$ 0.050	-0.221
KNN (传统)	0.490 $\pm$ 0.067	-0.246

此外，成员 4 对同一测试集施加亮度、对比度、高斯噪声、模糊、旋转裁剪等扰动：传统 SVM 在亮度 $\times 0.8$ 时准确率降至 31.7%，强噪声 ($\sigma=16$) 时降至 25%；RF 相对稳定但仍出现 5–15 pp 量级的回落。深度学习流水线未系统复现上述扰动实验，但 MobileNetV2 在课程定义的离线增强图上保持 79.1% 准确率，仍高于传统 RF (71.4%) 与 ResNet18 (75.8%)。

7.6 方法特性与适用场景

表 16: 传统方法 vs. 深度学习：综合对比

维度	传统（手工特征 SVM/RF/KNN）	+ 深度学习（ResNet18 / Mo- bileNetV2）
特征表示	可解释的颜色/纹理统计量,127 维，依赖领域设计	ImageNet 预训练卷积自动表 征，端到端微调
训练成本	特征提取一次 + 网格搜索约 1– 2 分钟	GPU 训练数十分钟,需调参(学 习率、早停等)
官方划分性 能	最佳 73.33% (RF)，满足课程 第 15 周定量要求	最佳 83.33% (MobileNetV2)， 适合课堂展示
增强图鲁棒 性	RF 增强子集 71.4%，SVM 原 图–增强差距大	MobileNetV2 增强 79.1%，整体 最优
严格分组泛 化	Macro-F1 约 0.49–0.58，波动较 大	未在测试集做严格分组；val 已 按病灶分组
临床相关	mel 召回偏低 (RF 0.69)	mel 召回 0.79，vasc 召回 0.94

结论性认识：在相同预处理与划分条件下，深度学习以更高上限完成三分类任务，MobileNetV2 为综合最优；传统 RF/SVM 实现简单、可解释、训练快，符合课程对传统方法的考核，但在有限样本皮肤镜任务上难以匹敌迁移学习。课程设计中的“传统 + 深度”双轨互补：前者展示特征工程与经典分类器基线，后者展示表示学习与鲁棒性优势。后续可在严格病灶分组测试集上统一评测深度模型，并探索“手工特征 + CNN 嵌入”融合。

8 结论

本实验完成了基于 ResNet18 与 MobileNetV2 的皮肤病变三分类迁移学习流水线，在预处理数据集上实现了训练、验证、测试全流程，并按原图/增强图分别评估。**Mo-
bileNetV2** 在测试集取得最佳整体性能（Accuracy 83.33%，Macro-F1 0.840），增强图子集准确率 79.1%，为所对比方法中最高。**ResNet18** 测试准确率 79.17%，对增强图泛化弱于 MobileNetV2，mel 召回为 0.69。

与 final_project 传统流水线对比：最佳传统模型 RF 测试准确率 73.33%、Macro-F1 0.736，增强子集约 71.4%；MobileNetV2 整体提升约 10 pp、增强子集提升约 8 pp。严格病灶分组下传统 Macro-F1 降至约 0.49–0.58，提示需在无泄漏划分下进一步验证深度模型。课程要求的双路径——传统方法满足定量基线，深度学习提供更高精度与增强鲁棒性。

已实现类别加权损失、Macro-F1 选模、训练曲线与错例可视化及 `output.csv` 推理脚本；后续可在严格分组测试集上复评深度模型，并尝试手工特征与 CNN 嵌入融合。

参考文献

1. He K, Zhang X, Ren S, Sun J. Deep Residual Learning for Image Recognition. CVPR, 2016.
2. Sandler M, Howard A, Zhu M, et al. MobileNetV2: Inverted Residuals and Linear Bottlenecks. CVPR, 2018.
3. 课程 Project 2 说明文档: `Project idea.pdf`
4. 实验代码与结果: `deep_learning/`, 评估结果 `deep_learning/outputs/results/`
5. 传统方法流水线: `final_project/`, 对比数据 `results/`、`results_member4/`

A 复现实验命令

`cd 大作业目录`

```
py -m pip install -r deep_learning/requirements.txt
```

```
py -m deep_learning.main --stats
```

```
py -m deep_learning.main --train --eval --plot --backbone all
```

```
py -m deep_learning.main --predict --backbone mobilenet_v2
```

```
py -m deep_learning.main --predict --submitdemo --backbone mobilenet_v2
```

输出文件包括:`model_comparison.csv`、`*_history.json`、`outputs/figures/` 下图、`output_mobilenet_v2.csv`,以及各划分的预测结果 CSV。关闭类别权重:加 `--no-class-weights`。

B 小组成员分工（请填写）

姓名	学号	主要贡献
----	----	------

		数据预处理
--	--	-------

		深度学习模型训练与评估
--	--	-------------

		实验报告撰写
--	--	--------
